

**Theorethische Grundlagen SIA**

ENTROPIE EINES WIRTSCHAFTSSYSTEMS

**Daniel Meiborg**

SIA - Schüler-Ingenieur-Akademie



Hr. Vogelgesang

Schule Birklehof e.V.

2022/2023

# Inhaltsverzeichnis

<b>Information</b>	<b>2</b>
Eigenschaften des Informationsgehalts . . . . .	2
<b>Entropie</b>	<b>3</b>
Arten und Anwendungen von Entropie . . . . .	3
Formale Definition . . . . .	3
Anschauliche Erläuterung . . . . .	3
Bedingte Entropie . . . . .	5
Relative Entropie . . . . .	6
<b>Markov-Prozesse</b>	<b>6</b>
Definition . . . . .	6
Beispiel . . . . .	7
Stationäre Verteilung . . . . .	7
<b>Zweiter Hauptsatz der Thermodynamik</b>	<b>7</b>
$H(X_n)$ steigt monoton . . . . .	8
$H(X_0 X_{-\infty}^n)$ steigt monoton . . . . .	8
<b>Quellen</b>	<b>9</b>

*You should call it entropy [...] no one really knows what entropy really is, so in a debate you will always have the advantage.*

John von Neumann zu Claude Shannon [1]

## Information

In der Informatik wird der Informationsgehalt, auch genannt Shannon-Information, als Menge an “Überraschung” eines Ereignisses definiert. Sei  $p(x)$  die Wahrscheinlichkeit des Ereignisses  $x$ . Dann ist der Informationsgehalt formal als  $I(x) = -\log_2(p(x))$  (in Bit) definiert. Hierbei ist zu beachten, dass diese Größe nichts mit dem im Sprachgebrauch verwendeten Begriff von *Inhalt* zu tun haben muss. Der Informationsgehalt sagt nichts darüber aus, wie nützlich die Nachricht ist. Stattdessen kann diese Größe als die natürliche Grenze für die Kompression einer Nachricht verstanden werden, oder als das Minimum an Ja-Nein Fragen, um das Ergebnis zu bestimmen (bei nicht-natürlichen Zahlen die durchschnittliche Anzahl).

Ein Beispiel: Eine typische faire Münze hat eine Wahrscheinlichkeit von  $1/2$  für Kopf und  $1/2$  für Zahl. Der Informationsgehalt für beide Ereignisse ist also jeweils  $-\log_2(1/2) = 1$  Bit. Bei einer nicht-fairen Münze mit einer Wahrscheinlichkeit von  $1/3$  für Kopf und  $2/3$  für Zahl ist der Informationsgehalt für Kopf  $-\log_2(1/3) \approx 1,585$  Bit und für Zahl  $-\log_2(2/3) \approx 0,585$  Bit.

## Eigenschaften des Informationsgehalts

Der Informationsgehalt ist eine streng monoton sinkende Funktion der Wahrscheinlichkeit, welche für  $(0, 1]$  definiert ist. Der Informationsgehalt von einem Ereignis, welches völlig sicher ist, also eine Wahrscheinlichkeit von 1 hat, ist 0. Der Informationsgehalt eines Ereignisses, welches nicht vorkommen kann, wäre  $\infty$ .

Der Informationsgehalt von zwei unabhängigen Ereignissen ist die Summe der beiden Informationsgehalte.

# Entropie

## Arten und Anwendungen von Entropie

Entropie findet sich in zahlreichen Einzelwissenschaft wieder. In der Physik findet man sie in Gestalt der quantenmechanisch definierten Von-Neumann-Entropie, in den Temperaturdifferenzen verschiedener Systeme und in der statistischen Mechanik. In der Chemie existiert die Reaktionsentropie. Jede verwendet eine etwas unterschiedliche Definition. In der Informatik wird hauptsächlich die Entropie nach Claude Shannon verwendet. Für die Zwecke dieser Arbeit wird ausschließlich die Shannon-Entropie verwendet und ist synonym mit Entropie zu verstehen.

## Formale Definition

Die Entropie ist der durchschnittliche Informationsgehalt einer zufälligen Variable. Sie ist definiert als  $H(X) = \sum_{x \in X} p(x) \cdot I(x) = -\sum_{x \in X} p(x) \cdot \log_2 p(x)$  (in Bit), wobei  $p(x)$  die Wahrscheinlichkeitsfunktion der zufälligen Variable ist.

## Anschauliche Erläuterung


Entropie wird oft als Maß für die Unordnung eines Systems beschrieben. Die Shannon-Entropie ist allerdings etwas abstrakter: Sie beschreibt die Verteilung von Wahrscheinlichkeiten.

Die Entropie ist eng mit der statistischen Mechanik verknüpft. In dieser hat ein Gas, welches gleichmäßig verteilt ist, eine hohe Entropie, während ein Zustand, in dem alle Gasmoleküle an einer Seite des Raumes sind, eine niedrige Entropie hat. Das hat den Grund, dass es deutlich mehr Zustände i.e. eine höhere Wahrscheinlichkeit gibt, dass der erste Zustand eintritt. Dieses Verhältnis entspricht allerdings eher der Information der Zustände als der Entropie des Systems.

Nehmen wir wieder das Beispiel mit der Münze: Bei der fairen Münze ist die Entropie  $\frac{1+1}{2} = 1$  Bit. Bei der nicht-fairen Münze ist die Entropie  $1,585 \cdot 1/3 + 0,585 \cdot 2/3 \approx 0,918$  Bit. Die Entropie ist also niedriger als bei der Einheitsverteilung. Diese Tatsache gilt für alle Wahrscheinlichkeiten i.e. die Einheitsverteilung hat immer die höchste Entropie. Verteilungen, bei denen

nur ein einziger Zustand möglich ist, haben die niedrigste mögliche Entropie von 0.

Ein anderes Beispiel: Folgendes Diagramm stellt die Verteilung von Energie in zwei Körpern dar. Ein Körper besteht hier aus zwei Partikeln, die jeweils eine Einheit Energie besitzen können. Auf der linken Seite sieht man die Menge an Energieeinheiten (rot = 2, grün = 1, blau = 0), die die beiden Partikel besitzen. Rechts sind die möglichen Zustände aufgelistet (Kreuz = hat eine Einheit Energie). Für eine gleichmäßige Verteilung der Energie zwischen den beiden Körpern gibt es mehr Möglichkeiten, also eine höhere Entropie (hier 2 bit). Eine ungleiche Verteilung hat dagegen eine niedrige Entropie (hier 0 bit).



## Bedingte Entropie

Sei  $H(X|Y) = \sum_{x,y} p(y)p(x|y) \log_2 p(x|y)$  die bedingte Entropie von  $X$  unter der Bedingung  $Y$ .  $H(X|Y)$  ist nie größer als  $H(X)$  und nur gleich, wenn  $Y$  vollkommen unabhängig von  $X$  ist. Das lässt sich anschaulich so erklären, dass zusätzliche Information ( $Y$ ) nicht Wissen über  $X$  zerstören kann, sondern höchstens vollkommen irrelevant sein kann.

## Relative Entropie

Seien  $p$  und  $r$  zwei Wahrscheinlichkeitsverteilungen für  $x$ . Dann ist  $D(p||r) = \sum_x p(x) \log_2 \frac{p(x)}{r(x)}$  die relative Entropie, auch Kullback-Leibler Divergenz genannt. Die relative Entropie ist ein Maß für die Unterschiedlichkeit zweier Wahrscheinlichkeitsverteilungen. Sie ist nicht symmetrisch, d.h.  $D(p||r) = D(r||p)$  gilt nicht unbedingt. Sie kann als Menge an Information interpretiert werden, die man von  $p$  erhält, wenn  $r$  gegeben ist.

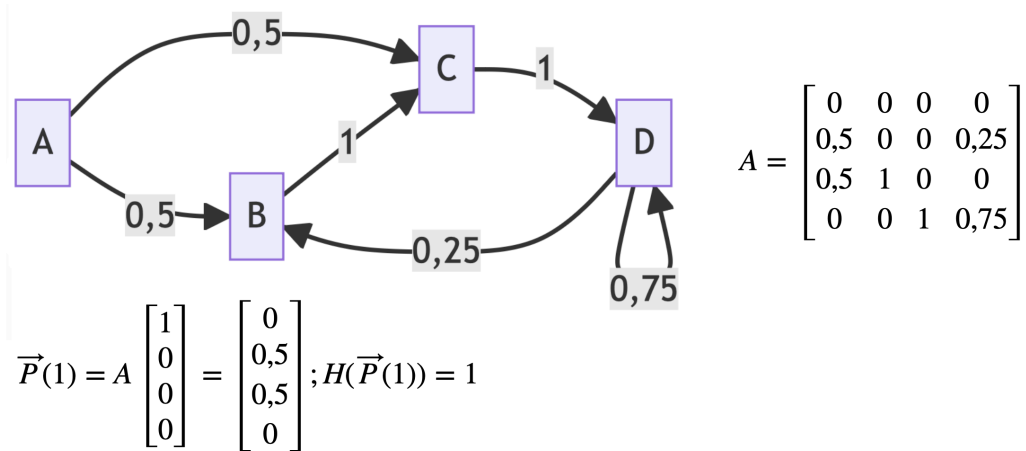
## Markov-Prozesse

Für diese Arbeit sollen lediglich endliche diskrete Markov-Prozesse betrachtet werden, i.e. Prozesse, bei denen es nur endlich viele Zustände gibt und die Zeit in diskreten Schritten abläuft.

### Definition

Ein Markov-Prozess, auch Markov Chain genannt, ist ein stochastischer Prozess, der die Markov-Eigenschaft besitzt. Er besteht aus einer Menge an Zuständen und einer Wahrscheinlichkeitsmatrix, die die Übergangswahrscheinlichkeiten zwischen den Zuständen beschreibt. Die Markov-Eigenschaft besagt, dass die Übergangswahrscheinlichkeiten ausschließlich von dem aktuellen Zustand abhängen. Sei  $A$  die Übergangsmatrix mit  $A_{ij}$  als Wahrscheinlichkeit, dass Zustand  $j$  in Zustand  $i$  übergeht, und  $\vec{P}(t)$  die Wahrscheinlichkeiten der Zustände zu Zeitpunkt  $t$  in Vektorform. Dann lautet die sogenannte Mastergleichung  $\vec{P}(t+1) = A\vec{P}(t)$ .

## Beispiel



## Stationäre Verteilung

Die stationäre Wahrscheinlichkeitsverteilung eines Markov-Prozesses ist die Verteilung  $\vec{P}$ , die erfüllt, dass  $\vec{P} = A\vec{P}$ . Die stationäre Verteilung ist ein Gleichgewichtszustand des Prozesses.

## Zweiter Hauptsatz der Thermodynamik

Für den zweiten Hauptsatz der Thermodynamik existiert keine eindeutige Formulierung. Alle Formulierungen aber enthalten die folgende Kernaussage:

*Entropie kann in einem geschlossenem thermodynamischen System nicht abnehmen.*

Diese Aussage lässt sich bis zu einem gewissen Grad allgemein auf stochastische Prozesse zurückführen. Die Beweise dafür wurden in diesem Paper geführt [2], aus dem im Folgendem die wichtigsten Aussagen und Beweise skizziert sind. Die Notation  $X_n$  bezeichnet den Zustand des Systems zu Zeitpunkt  $n$  und  $X_k^n$  die Menge aller Zustände vom Zeitpunkt  $n$  bis  $k$ .



## $H(X_n)$ steigt monoton

$H(X_n)$  steigt monoton für alle endlichen diskreten Markov-Prozesse, wenn die stationäre Verteilung uniform ist.

Sei  $m$  die Anzahl an möglichen Zuständen,  $\mu_n$  eine Wahrscheinlichkeitsverteilung zu Zeitpunkt  $n$  und  $\mu$  die stationäre Verteilung, in diesem Fall die Einheitsverteilung. Dann ist

$$D(\mu_n || \mu) = \sum_x \mu_n(x) \cdot \log_2\left(\frac{\mu_n(x)}{1/m}\right) = -H(\mu_n) + \log_2(m)$$

Da  $D(\mu_n || \mu)$  monoton sinkt [2], steigt  $H(\mu_n)$  monoton.

Dieser Satz lässt sich wie folgt verstehen: Angenommen, man hat einen Markov-Prozess, keine Informationen über den vorherrschenden Zustand (allerdings kennt man die prinzipiell möglichen Zustände und die Übergangswahrscheinlichkeiten) und führt den Prozess für eine gewisse Zeit aus. Wenn man danach nicht genauer sagen kann, welche Zustände wie wahrscheinlich sind, gilt der zweite Hauptsatz der Thermodynamik.

## $H(X_0 | X_{-\infty}^{-n})$ steigt monoton

Die bedingte Entropie  $H(X_0 | X_{-\infty}^{-n}) = H(X_0 | X_{-n}, X_{-(n+1)}, \dots)$  der Gegenwart mit der gegebenen Vergangenheit steigt monoton für alle stochastischen Prozesse.

Man kann  $H(X_0 | X_{-\infty}^{-n})$  auch wie folgt darstellen:

$$H(X_0 | X_{-\infty}^{-n}) = H(X_0 | X_{-\infty}^{-(n+1)}, X_{-n})$$

Zusätzliche Information kann die Entropie nicht erhöhen. (Bedingte Entropie). Also gilt

$$H(X_0 | X_{-\infty}^{-(n+1)}, X_{-n}) \leq H(X_0 | X_{-\infty}^{-(n+1)})$$

und damit

$$H(X_0 | X_{-\infty}^{-n}) \leq H(X_0 | X_{-\infty}^{-(n+1)}).$$

Anschaulich bedeutet das, dass wenn man die Information über die Vergangenheit  $X_{-n}$  ignoriert, man dadurch nur Information über die Gegenwart verlieren kann.

## Quellen

- [1] M. Tribus and E. C. McIrvine, “ENERGY AND INFORMATION,” *Scientific American*, vol. 225, no. 3, pp. 179–190, 1971 [Online]. Available: <http://www.jstor.org/stable/24923125>. [Accessed: Jan. 09, 2023]
- [2] T. M. Cover and J. Halliwell, “Which processes satisfy the second law,” *Cambridge University Press New York, NY*, pp. 98–107, 1994.